MindTrace

数学学习笔记与可追溯复习助手

鸿蒙原生 · 本地优先 · A2A 草稿确认 · 五路混合检索。 把拍照、文字和小艺消息整理成可确认、可追溯、可复习的结构化笔记。

5	576	1,361	3.2s
模块	ArkTS 文件	单元测试	A2A 草稿

把数学材料，整理成可追溯的笔记

数学材料天然分散：截图、题目、公式、零散文字。通用 AI 能回答但不可追溯；笔记应用能保存但整理成本高。 MindTrace 把“输入—整理—确认—复习—溯源”串成一条链路。

1,361	3.2s	220ms	25s
单测通过	A2A 草稿生成	确认入库	模型挂起兜底

问题

材料散、整理贵、回答虚

截图和题目散落在相册与聊天里；通用回答看似流畅，但无法回到“我的笔记”和具体版本。

方案

草稿确认 + 本地检索

先出草稿，用户确认才入库；复习时基于个人笔记检索，回答带来源、摘要与融合分。

角色

独立设计与实现

产品流程、五模块架构、A2A 链路、检索与判重、测试与真机验证均由本人完成。

三个产品判断

- **草稿是中间态。**确认前不创建正式笔记；取消、重新生成都不写库。
- **相似不等于重复。**补充内容照常写入并给合并建议，不因为“像”就丢掉。
- **够不够回答，是显式策略。**strict / balanced / expansive 三档由调用方选择，不藏在检索实现里。

范围与边界

已交付

四条入口 + 草稿确认

应用内拍照/批量/文字、A2A 文本与计划、对话回忆；确认前不写库。

已交付

检索与判重

五路召回、证据判定、三分类判重、幂等写入、schema v23。

不在本轮

上架与端侧模型

测试态不推进应用市场；端侧模型受设备形态限制，未做全量验证。

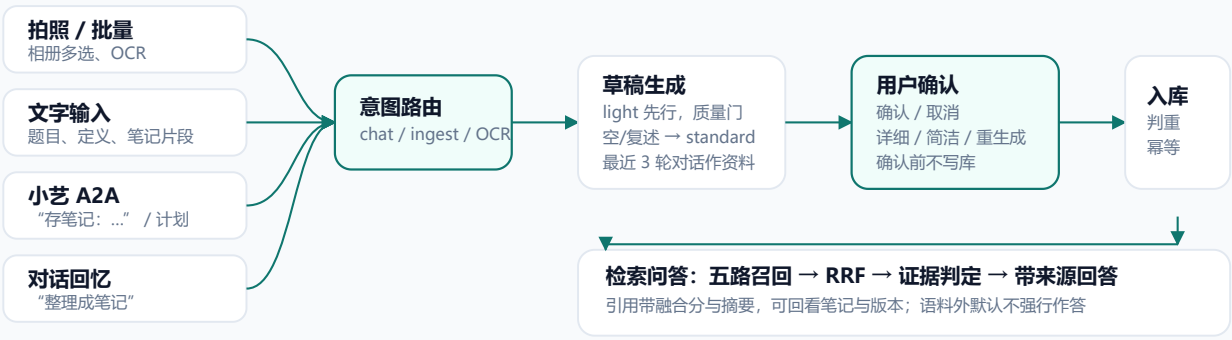
> 项目处于测试态，未上架应用市场。本介绍只陈述有真机或自动化测试记录的能力； 未验证与平台阻塞项在第 11 页单独列出。

四种入口，同一条确认链路

入口可以很多，写入只能有一套规则：先出草稿、用户确认、再判重入库。失败不丢输入，统一转待整理。

PRODUCT FLOW

四种入口，同一条“先确认、后入库”的链路



设计要点：草稿是“可退回的中间态”，不是正式笔记；失败统一转待整理，不丢用户输入。

应用内

拍照 / 批量 / 文字

相册多选最多 20 张，OCR 后按题规划；单题直接草稿，多题逐题预览、逐题确认。文字入口适合从聊天或文档粘贴。

系统入口

小艺 A2A / 对话回忆

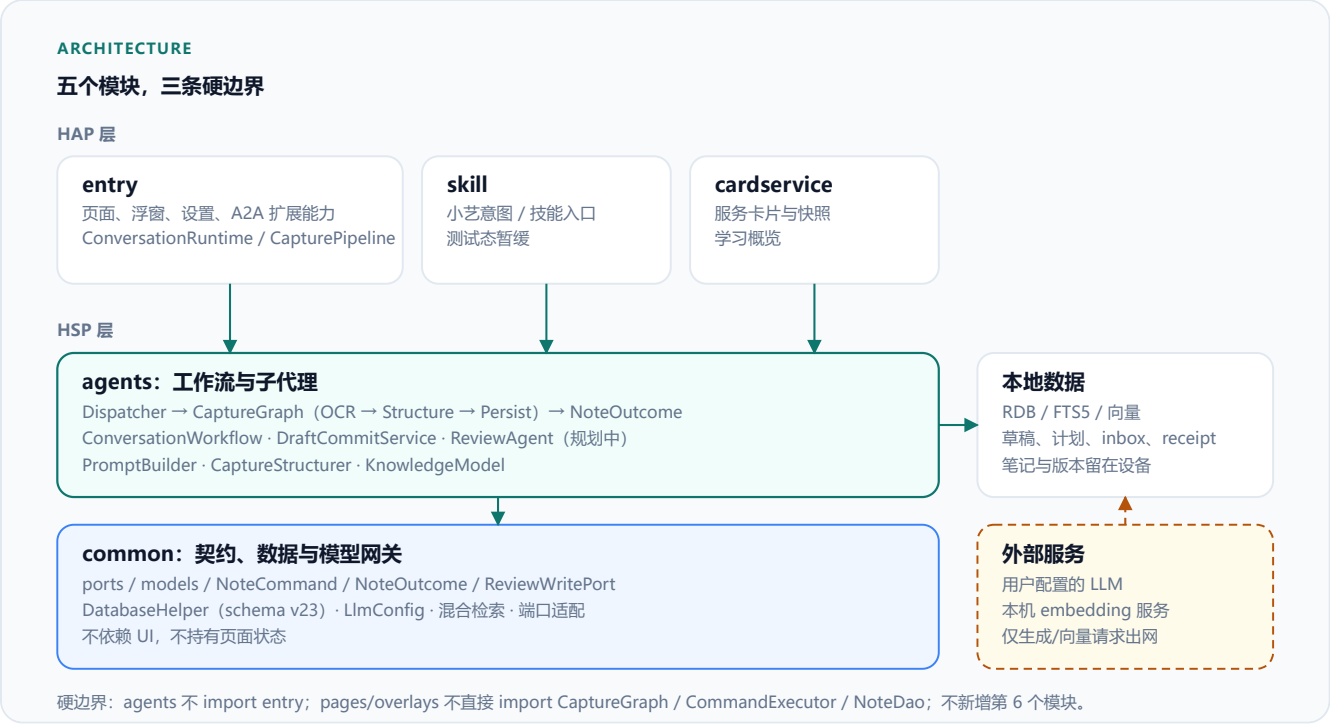
小艺里说“存笔记：矩阵的秩”，先回标题和要点，再问是否保存；先问一道题再说“整理成笔记”，用上一轮问答作资料。

一条笔记的路径

阶段	做什么	关键约束
路由	识别 chat / ingest / OCR / 计划推进	短命令才当确认，避免误判提问
生成	light 先行，质量门不过改 standard	3–6s 目标；空/复述原文不算可用草稿
落盘	按 conversationKey 保存 24h	跨轮次确认；计划项保存进度
预览	标题、学科/题型、最多 4 节要点	最后才问是否整理保存
二次操作	详细 / 简洁 / 重新生成	新稿成功后才覆盖旧稿
入库	判重、幂等写入、回执	确认前不创建正式笔记

五个模块，三条硬边界

模块数量不是重点；重点是页面不直接碰图执行器，agents 不反向依赖 entry，数据契约留在 common。



边界 01

agents 不依赖 entry

工作流可被 A2A、应用内、后台任务复用；反向 import 会让三个入口重新耦合。

边界 02

页面不碰执行器

pages / overlays 不能直接 import CaptureGraph、CommandExecutor 或 NoteDao。

边界 03

不新增第 6 个模块

新能力优先放进 common 的端口或 agents 的子代理。

本地与云端

留在设备

笔记、草稿、计划、判重、检索索引、inbox 与回执都在应用沙箱；本地 BGE 服务优先。

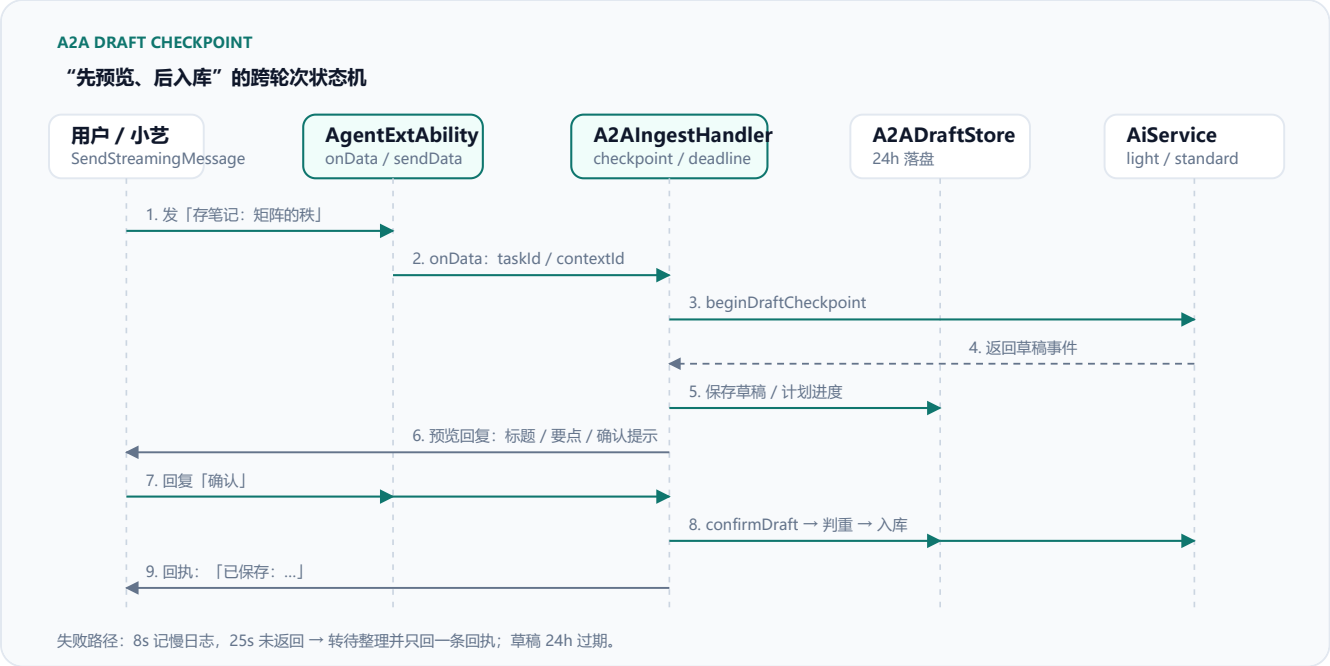
会出网

用户配置的 LLM（生成、回答、查询改写）与可选云端 embedding；只发送生成所需的最小上下文。

> 小艺 A2A 只把用户主动发送的消息和生成所需的最小上下文带进扩展；本地笔记不会因为 A2A 而整体上传。

在小艺里，先看内容再保存

A2A 单任务只允许一次最终回复。所以草稿必须落盘、跨轮次确认，失败要能转待整理，而不是让用户重发。



确认

确认 / 保存 / 好的 → confirmDraft；命中判重时复用已有笔记。

取消

取消 / 不要了 / 算了 → 丢弃草稿；计划项同时取消计划。

二次操作

详细走 standard；简洁、重新生成走 light；失败保留旧稿。

> 命令只认短句：不超过 10 个字符，避免把“保存到哪里”这类问题误判为确认。

草稿里存什么

字段	用途
`conversationKey`	跨轮次找回草稿；小艺会话上下文
`event`	标题、学科、题型、章节与正文
`sourceText`	“详细 / 简洁 / 重新生成”的原始资料
`planTaskId / planItemIndex`	计划项确认后回写进度
`createdAt`	24h 过期与清理

模型慢、模型挂、内容为空时怎么办

产品体验的差异往往在失败路径。这里的取舍是：宁可转待整理，也不让用户无限等，更不允许一次请求回两条互相矛盾的回执。

动作	路由	真机耗时	结果
生成草稿	light	**3.2s**	标题 + 4 段要点 + 确认提示
详细一点	standard	**11.4s**	636 字，补充推导与易错点
简洁一点	light	**1.3s**	107 字，核心定义与结论
重新生成	light	**2.5s**	247 字，保留标准字段
确认入库	判重 + 写入	**220ms**	“已保存：矩阵的秩与初等变换（线性代数）。”
超时兜底	入队	**25s**	只回一条，转待整理

失败路径

场景	处理	用户看到
8s 未返回	记慢请求日志，不打断生成	无变化，继续等
25s 未返回	取消 token，入待整理队列	“这次整理较慢，已转待整理……”
草稿为空 / 复述原文	取消 run，改 standard 重试	稍慢，但拿到可用草稿
确认时命中判重	复用已有笔记，不重复创建	“已保存（复用）：……”
计划某题失败	保留计划进度，可继续/取消	“第 N 题这次没整理成……”

> 回执去重：入队函数统一负责“入队 + 一条回执”，调用方不再单独回话；单题可重试路径也不再重复入队。

改动前后

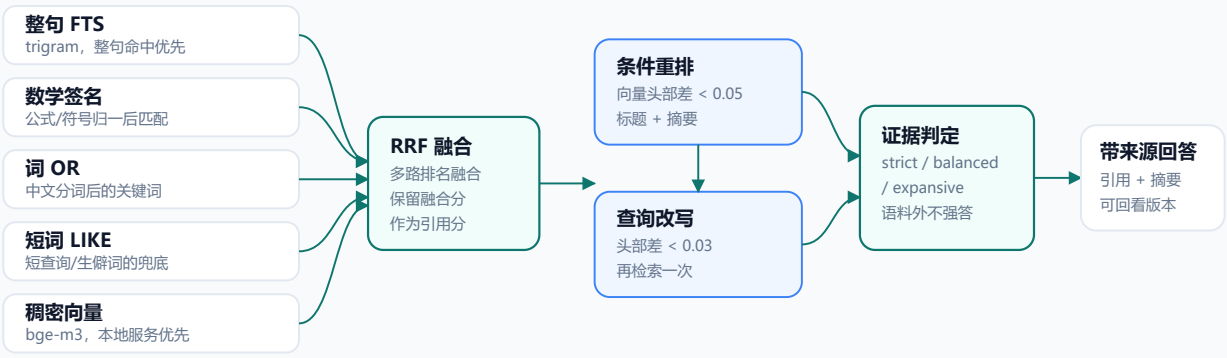
维度	改动前	改动后
写入时机	收到文本直接入库	先生成草稿，确认后才入库
模型挂起	最长等 90s	25s 回执并转待整理
失败回执	入队与调用方各回一条	统一只回一条
单题重试	请求文本可能重复入队	多题才补剩余题，单题只入一次

先找得到，再判断够不够

五路召回解决“换个说法就搜不到”；证据判定解决“搜到了但不该拿来回答”。两件事分开，策略才能显式配置。

RETRIEVAL PIPELINE

五路召回先融合，再判断“这些材料够不够回答”



MathNet-Retrieve 结论：2,000 候选池上纯向量最好；等权 RRF 会把向量排对的条目挤下去；条件重排在该基准上为负优化。

通道	解决什么	边界
整句 FTS	原句或高度重合的表述	换说法就失效
数学签名	公式、符号、结构相似	依赖归一化质量
词 OR	关键词部分命中	长题干噪声多
短词 LIKE	短查询、生僻词	只适合兜底
稠密向量	语义等价、改写	需要本地或云端 embedding

证据策略是调用方输入

strict

判定不可用时 fail-closed，视为无证据。

balanced

默认档；判定不可用时 fail-open，保留候选。

expansive

跳过判定，允许证据不足时继续。

条件触发与代价

阶段	触发条件	代价 / 取舍
RRF 融合	每一路返回候选后	保留融合分作为引用分；等权会放大词面噪声
条件重排	向量头部差 < 0.05	MathNet 上 79 次触发、480s，hit@1 再降 10 条
查询改写	向量头部差 < 0.03	多一次 LLM 调用，只在头部很接近时启用

在公开基准上验证检索方案

MathNet-Retrieve：15,000 条查询 / 117,088 条语料。这里使用 easy 档中文子集 334 条查询、固定 2,000 候选池， 对比词面、向量、混合与重排四条路线。

变体	HIT@1	HIT@5	MRR	NDCG@10
词面 BM25	216	262	0.705	0.734
向量 body	**286**	**314**	**0.895**	**0.914**
混合 body（RRF）	242	296	0.793	0.833
混合 + 条件重排	232	288	0.766	0.804

结论

向量应作主召回

2,000 候选池上纯向量最好；等权 RRF 会稀释向量排名。条件重排在该基准上是负优化（79 次触发、480s，hit@1 再降 10 条）。

限制

排序有效性高于绝对值

候选池只抽 2,000 条且含约 16.7% gold，命中率不能和全语料 BEIR 榜单直接比较。

全语料词面基线：BM25 hit@1 22/334（6.6%）、hit@5 187/334。等价改写场景下，词面通道无法承担主召回。

评测方法

数据

公开基准

MathNet-Retrieve（CC-BY-4.0）；easy 档中文子集 334 条查询，按 CJK 过滤。

候选池

2,000 条固定抽样

包含全部 334 条 gold；随机命中基线约 16.7%，用于比较排序而非绝对值。

脚本

可复现

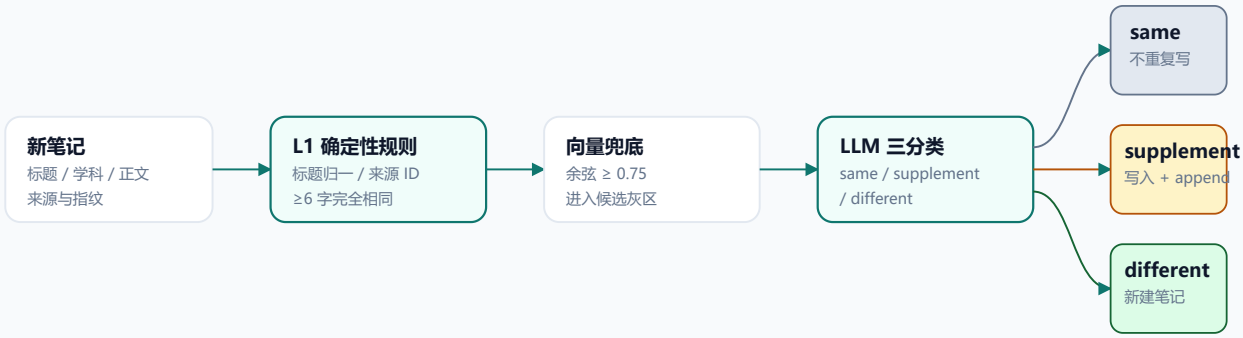
fetch-mathnet.mjs + eval.mjs；数据缓存 git 忽略，结果写入研究日志。

相似不等于重复，写入必须幂等

判重、幂等写入和测试门禁解决同一个问题：跨入口、跨进程改同一份数据时，结果要可预测。

DEDUPE DECISION

判重不是“相似就丢”：三种裁决对应三种写入动作



标定结论：18 条样本中 same 与 supplement 在高分段重叠，且没有 different 负样本，因此不能按向量分砍掉 LLM 仲裁。

裁决	含义	动作	用户可见
same	同一内容	不重复写，复用已有笔记	“已保存（复用）：……”
supplement	相关但新增了信息	照常写入，并发 append 建议	新笔记 + 合并建议
different	只是相似，不是同一主题	新建笔记	正常保存

18
去重后的标定样本

0.781–0.960
向量分范围

0
different 负样本

> same 最高 0.960，supplement 最高 0.953，在高分段完全重叠，而两者的正确动作相反（拦下 vs 写入）。 所以当前必须保留 LLM 仲裁，不能按向量分设免仲裁窗口。

每次改动都能回到同一条验收线

本地提交前跑质量门；契约测试守住跨模块边界；真机冒烟验证平台链路。没有 gate 输出的"已完成"不算完成。

检查	结果	作用
arkts-lint	PASS	ArkTS 严格模式规则
naming-lint	PASS	文件、目录、符号命名
link-check	PASS	文档链接可达
doc-trace	PASS	文档索引与编号唯一
process-boundary	PASS	6 个入口 / 429 个文件可达，受限能力不越界
hypium-check	PASS	22 个测试源与生成物一致
unit-tests	1,361 通过	契约测试 + 单元测试

代码阅读顺序

```
1. A2AIngestHandler.ets      草稿 checkpoint / 超时 / 单回执
2. A2ADraftModels.ets        命令解析 / 预览文案
3. RagNoteEvidenceSearch.ets 混合召回与证据接线
4. ReviewWritePortAdapter.ets + ReviewWriteStoreDao.ets
                             operationId 幂等 / schema v23
5. a2a-draft-checkpoint.test.mjs
                             契约测试与源码守卫
```

5
HAP / HSP 模块

576
ArkTS 文件

24 + 35
ADR + spec

1,323
次提交（4 个月）

真机验证样例

批量

OCR → 计划 → 入库

多题逐题预览，确认一题保存一题；计划进度可继续、可取消。

A2A

草稿确认 + 二次操作

3.2s 预览；详细 11.4s、简洁 1.3s、重新生成 2.5s；确认 220ms 入库。

失败

模型挂起兜底

8s 慢日志，25s 转待整理；真机只出现一条回执，pending 计数递增。

哪些已验证，哪些还没

“已实现”不等于“已验证”。下面把能力状态单独列出，避免把测试态项目说成已上线产品。

能力	状态	说明
应用内拍照 / 批量 / 文字	已验证	真机批量、OCR、草稿确认与入库
A2A 草稿确认 / 二次操作	已验证	3XTYD24C16203663 真机 + 冒烟脚本
混合检索 / 证据判定	已验证	MathNet 离线评测 + 真机探针
判重三分类 / 幂等写入	已验证	契约测试 + schema v23 迁移
A2A 图片输入	平台阻塞	小艺客户端不下发 image parts；应用内批量不受影响
A2A 长文本流式	部分	短回复可增量渲染；长文本会被客户端截断
端侧模型	部分	受设备形态限制，未做全量验证
上架 / 意图注册	暂缓	测试态，依赖平台审核与上架

如果继续做

- **RRF 权重：**按 MathNet 结论改成向量为主、词面降权，并用向量索引做全语料召回。
- **评测负样本：**补“相关但不同 / 完全无关”，再评估判重免仲裁窗口。
- **A2A 长文本：**等云端流式或客户端修复；当前长回答坚持单帧快照。
- **上架材料：**隐私政策、AI 标识、权限清单、应用市场截图与介绍文案。

三个主要取舍

时延

25s 封顶，而不是继续等

正常草稿 3.2s；25s 足够覆盖慢请求。继续等只会让用户重发，反而制造重复请求。

判重

保留 LLM 仲裁

18 条样本无法区分高分段 same / supplement，也没有 different 负样本；砍掉仲裁会误合并。

流式

长文本坚持单帧

小艺客户端会截断长 artifactUpdate；短回复才分块，长回答用完整的 result.task 快照。

从“能回答”到“能确认、能追溯”

这个项目最想展示的不是功能数量，而是三个判断：写入前先确认，回答前先判断证据， 相似内容不要轻易丢掉。剩下的是把这些判断落到跨进程、跨入口的工程约束里。

PDF

12 页项目介绍

本文件，可直接阅读或分享。

GitHub

github.com/YunC-GCT/MindTrace

源码、ADR、spec、研究日志与评测脚本；公开用于项目介绍与技术交流。

HTML

portfolio/

六页设计说明：首页、流程、架构、A2A、检索、质量。

演示

3 分钟真机流程

拍照/批量 → 草稿确认 → 小艺 A2A → 检索问答 → 超时兜底。

3 分钟演示脚本

时间	演示内容	要证明什么
0:00–0:30	一句话定位 + 四条入口	产品问题与范围
0:30–1:30	拍照/批量 → 草稿 → 确认保存	确认前不写库
1:30–2:15	小艺 A2A → 详细一点 → 确认	跨轮次草稿与二次操作
2:15–2:45	基于笔记提问 → 来源	检索与可追溯
2:45–3:00	模型慢 → 25s 回执	失败兜底

说明：项目处于测试态，未上架；本介绍只引用有记录的真机或自动化测试结果， 检索指标只引用公开基准 MathNet-Retrieve。